Instituto de Ciência, Tecnologia e Inovação
Campus de São Sebastião do Paraíso
CIUFLA 2026

# Introdução ao R para Análise de Dados

Prof. Dr. Cássius Henrique Xavier Oliveira

**Descrição**

A oficina tem como objetivo introduzir o uso do R e do RStudio para organização, exploração e visualização de dados, com foco em aplicações em Engenharia.

Serão abordados conceitos básicos de objetos e estruturas de dados, importação e inspeção de bases, cálculo de medidas descritivas, construção de tabelas de frequência e elaboração de gráficos.

As atividades práticas serão desenvolvidas pelos participantes diretamente no RStudio, utilizando um banco de dados relacionado à Engenharia.

Os participantes executarão comandos para importar e inspecionar dados, calcular médias, medianas, desvios-padrão e frequências, comparar grupos descritivamente e construir histogramas, *boxplots* e diagramas de dispersão. Também serão introduzidas análises bidimensionais para explorar relações entre variáveis quantitativas e qualitativas.

**Material de apoio**

Carga horária: 3 horas

São Sebastião do Paraíso/MG
2026

## Sobre o professor

Cássius Henrique Xavier Oliveira é professor e pesquisador do **Instituto de Ciência, Tecnologia e Inovação (ICTIN)** da **Universidade Federal de Lavras (UFLA)**, com atuação em Estatística, Análise de Sobrevivência e Confiabilidade.

**Doutorado em Estatística**
Universidade Federal de Minas Gerais – UFMG

**Mestrado em Engenharia de Produção**
Universidade Federal de Minas Gerais – UFMG

**Graduação em Engenharia de Produção**
Universidade Federal de Ouro Preto – UFOP

# Sumário

**Como utilizar esta apostila** **4**

**1 Instalação do R e do RStudio** **4**
1.1 O que precisa ser instalado? . . . 4
1.2 Instalando o R . . . 5
1.3 Instalando o RStudio Desktop . . . 5
1.4 Verificando a instalação . . . 5

**2 Primeiros passos: interface, *scripts* e comandos** **6**
2.1 A interface do RStudio . . . 6
2.2 Criando o primeiro *script* . . . 7
2.3 Seu primeiro comando . . . 7
2.4 Funções e argumentos . . . 7
2.5 Objetos e atribuição . . . 8
2.6 Comentários . . . 8
2.7 Consultando a ajuda . . . 8

**3 Banco de dados da oficina: Cars93** **10**
3.1 Contexto do banco . . . 10
3.2 Carregando o banco . . . 10
3.3 Tradução das variáveis . . . 11
3.4 O que é um data frame? . . . 11

**4 Inspeção, seleção e qualidade dos dados** **12**
4.1 Inspeção inicial . . . 12
4.2 Acessando colunas . . . 13
4.3 Filtrando linhas . . . 13
4.4 Valores ausentes . . . 13
4.5 Exportando e importando um CSV . . . 14

**5 Análise exploratória unidimensional** **15**
5.1 A análise descritiva como etapa de exploração . . . 15
5.2 Variáveis qualitativas . . . 15
5.2.1 Tabelas de frequência e gráfico de barras . . . 15
5.3 Variáveis quantitativas . . . 16
5.3.1 Medidas de posição . . . 16
5.3.2 Mínimo, máximo, amplitude e quantis . . . 16
5.3.3 Variância e desvio-padrão . . . 16
5.3.4 Histograma . . . 17
5.3.5 Boxplot . . . 17

**6 Análise exploratória das relações entre variáveis** **19**
6.1 Duas variáveis quantitativas . . . 19

6.2 Várias variáveis quantitativas . . . . . 20
6.3 Uma variável quantitativa e uma qualitativa . . . . . 21
6.4 Duas variáveis qualitativas . . . . . 21

**7 Análise integrada e reprodutibilidade 23**
7.1 Do comando isolado ao fluxo de análise . . . . . 23
7.2 Reprodutibilidade . . . . . 24
7.3 Erros fazem parte do processo . . . . . 25

**Síntese: comandos essenciais da oficina 26**

**O que estudar depois desta oficina 27**

**8 Exercício final: análise de dados de qualidade do ar 28**
8.1 Contexto do banco . . . . . 28
8.2 Descrição das variáveis . . . . . 28
8.3 Problema . . . . . 29

**Gabarito comentado dos exercícios 30**

**Referências 39**

## Como utilizar esta apostila

Esta apostila foi organizada para que o participante execute os comandos enquanto lê. A aprendizagem de R é essencialmente operacional: a leitura ajuda a compreender a sintaxe, mas a consolidação ocorre quando o usuário escreve, executa, modifica e interpreta o código. Esse princípio é coerente com a natureza interativa do ambiente R e com abordagens modernas de ensino de ciência de dados (R Core Team, 2026; Wickham, Çetinkaya-Rundel e Grolemund, 2023).

A oficina utiliza o banco `Cars93`, disponibilizado no pacote `MASS`. Trata-se de um conjunto real com informações de 93 modelos de automóveis comercializados nos Estados Unidos em 1993, contendo variáveis econômicas e técnicas, como preço, consumo de combustível, potência, cilindrada, peso, tipo de tração e categoria do veículo (Lock, 1993; Venables e Ripley, 2002). O banco é útil para uma introdução aplicada à Engenharia porque permite estudar simultaneamente características de produto, desempenho, eficiência energética e preço.

**Regra de uso**

Sempre que aparecer um bloco de código, digite-o no *script* do `RStudio` e execute-o. Evite apenas copiar e colar mecanicamente, pelo menos no início. Digitar os primeiros comandos ajuda a perceber parênteses, vírgulas, aspas, operadores e nomes de objetos, que constituem fontes frequentes de erro para iniciantes.

**Antes de avançar**

O objetivo não é memorizar comandos. Ao final da oficina, o participante deverá compreender a lógica básica de uma análise: obter os dados, inspecionar sua estrutura, selecionar variáveis, produzir medidas e gráficos adequados e interpretar os resultados no contexto do problema.

# 1 Instalação do R e do RStudio

**Objetivos da seção**

Ao final desta seção, o participante deverá ser capaz de:

- distinguir o R do RStudio;
- localizar os sites oficiais para instalação;
- instalar primeiro o R e depois o RStudio;
- verificar se a instalação está funcionando corretamente.

## 1.1 O que precisa ser instalado?

Para acompanhar a oficina em um computador pessoal, são necessários dois programas:




- **R**: linguagem e ambiente no qual os cálculos estatísticos e os comandos são efetivamente executados (R Core Team, 2026);
- **RStudio**: ambiente integrado de desenvolvimento que fornece editor de *scripts*, console, gerenciador de arquivos, gráficos, ajuda e outras ferramentas para trabalhar com R (Posit Software, 2026).

## 1.2 Instalando o R

O R pode ser obtido gratuitamente por meio da rede oficial CRAN (*Comprehensive R Archive Network*):

`https://cran.r-project.org/`

No Windows, o procedimento usual é:

1. acessar o endereço acima;
2. clicar em `Download R for Windows`;
3. clicar em `base`;
4. baixar a versão atual do instalador;
5. executar o arquivo baixado e seguir as opções padrão de instalação.

O site oficial do R informa que o software é gratuito e está disponível para Windows, macOS e diferentes sistemas Unix/Linux (R Core Team, 2026).

## 1.3 Instalando o RStudio Desktop

Depois de instalar o R, instale o RStudio Desktop (opcional, mas recomedável). A página oficial de download é:

`https://posit.co/download/rstudio-desktop/`

A documentação oficial também pode ser acessada em:

`https://docs.posit.co/ide/user/download.html`

Escolha o instalador correspondente ao seu sistema operacional, execute-o e siga as instruções. O RStudio Desktop depende de uma instalação prévia do R (Posit Software, 2026).

## 1.4 Verificando a instalação

**Exercício prático – Seção 1**

1. Abra o RStudio. No painel do canto inferior esquerdo, digite `R.version.string` e aperte ENTER para identificar a versão do R utilizada na sessão.

# 2 Primeiros passos: interface, *scripts* e comandos

**Objetivos da seção**

Ao final desta seção, o participante deverá ser capaz de:

- reconhecer os principais painéis do RStudio;
- criar e salvar um *script*;
- executar comandos e interpretar resultados básicos do console;
- utilizar funções, argumentos, comentários e a ajuda interna do R.

## 2.1 A interface do RStudio

A disposição dos painéis pode ser personalizada. Na configuração apresentada na Figura 1, observam-se quatro regiões principais.

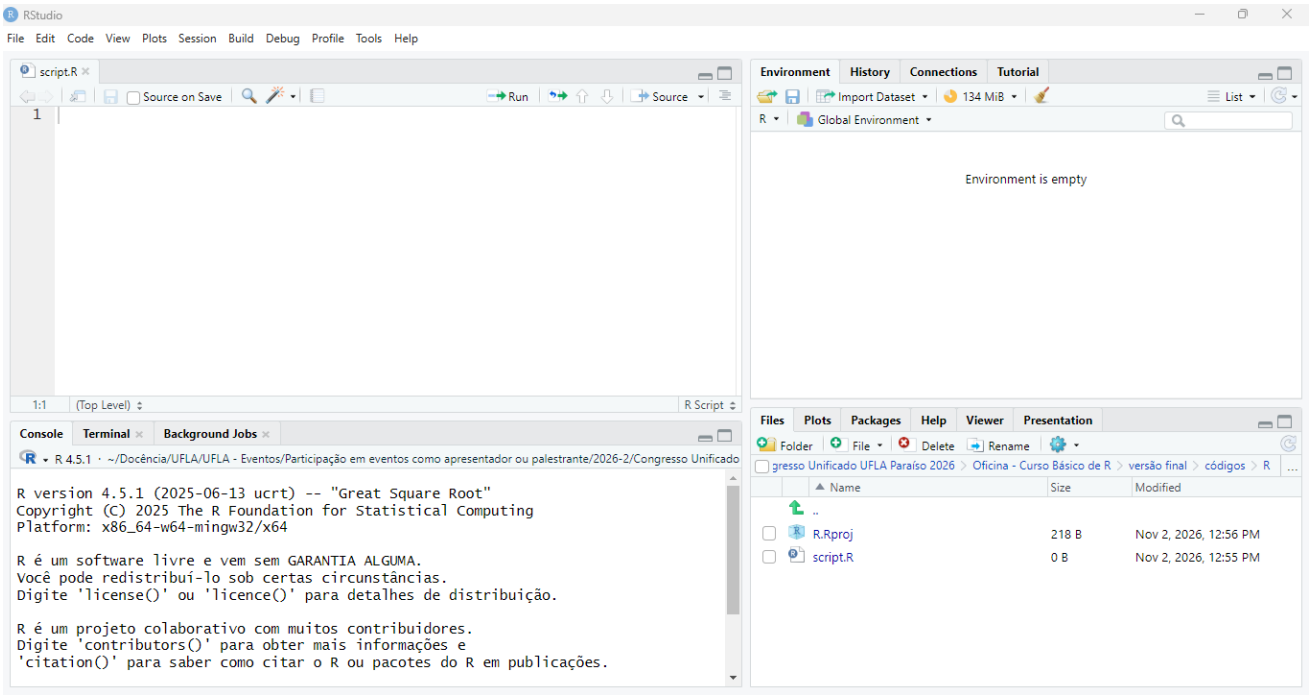



Figura 1: Interface do RStudio utilizada como referência nesta oficina.

1. **Barra de ferramentas** – localizada na parte superior da interface: reúne atalhos para operações frequentes, como criar e abrir arquivos, salvar *scripts*, executar comandos, interromper execuções e acessar recursos de organização do projeto.
2. **Source** – região superior esquerda: editor no qual são escritos e salvos os *scripts*. Na figura, o arquivo aberto contém um *script* de R;
3. **Console** – região inferior esquerda: local em que o R recebe os comandos e apresenta resultados, mensagens, avisos e erros;
4. **Environment/History** – região superior direita: permite visualizar objetos existentes na sessão e o histórico de comandos;
5. **Files/Plots/Packages/Help** – região inferior direita: reúne recursos para navegação em arquivos, visualização de gráficos, gerenciamento de pacotes e consulta à documentação.

A aparência pode variar entre versões e computadores, mas a função conceitual desses painéis permanece semelhante (Posit Software, 2026).

## 2.2 Criando o primeiro *script*

No RStudio, crie um novo *script* R por meio de:

`File` → `New File` → `R Script`.

Salve-o com um nome informativo, por exemplo:

`oficina_introducao_R.R`

Evite nomes genéricos como `novo.R`, `teste.R` ou `arquivo1.R`. O nome do arquivo deve ajudar a identificar seu conteúdo.

## 2.3 Seu primeiro comando

Digite no *script*:

```
2 + 3
```

Posicione o cursor na linha e execute-a. No Windows/Linux, um atalho usual é `Ctrl+Enter`; no macOS, `Cmd+Enter`.

O console deverá retornar:

```
[1] 5
```

O marcador `[1]` não faz parte do valor. Ele indica que o primeiro elemento exibido naquela linha é o elemento 1 do resultado.

Teste outras operações:

```
10 - 4
6 * 7
20 / 5
2^3
sqrt(81)
log(10)
```

Aqui, `^` representa potenciação, `sqrt()` calcula a raiz quadrada e `log()` calcula, por padrão, o logaritmo natural.

## 2.4 Funções e argumentos

Grande parte do trabalho em R consiste em chamar funções. A forma geral é:

`nome_da_funcao(argumento1, argumento2, ...)`

Por exemplo:

```
round(3.14159265, digits = 3)
```

Nesse comando, `round` é o nome da função, `3.14159265` é o valor processado e `digits = 3` define o número de casas decimais mantidas.

## 2.5 Objetos e atribuição

Resultados podem ser armazenados em objetos. O operador tradicional de atribuição é `<-`.

```
preco <- 25.4
potencia <- 180
relacao <- preco / potencia
relacao
```

A primeira linha cria o objeto `preco`; a segunda cria `potencia`; a terceira utiliza ambos em um novo cálculo.

**Nomes de objetos**

Prefira nomes curtos, informativos e consistentes. Evite espaços e caracteres especiais. Nomes como `preco_medio`, `peso_kg` e `consumo_cidade` tornam o *script* mais legível do que nomes genéricos como `x1`, `teste` ou `valor2`.
Não utilize palavras reservadas como nomes de objetos:

- `if`, `else`, `repeat`, `while`, `function`, `for`, `in`, `next` e `break`;
- `TRUE`, `FALSE`, `NULL`, `Inf`, `NaN`, `NA`, `NA_integer_`, `NA_real_`, `NA_complex_` e `NA_character_`.

Também têm uso reservado `...`, `..1`, `..2` etc., relacionados aos argumentos de funções. Evite ainda nomes de funções existentes, como `c`, `mean` e `sum`, e os nomes `T` e `F`, usados como abreviações de `TRUE` e `FALSE`. Embora não sejam reservados, seu uso pode causar confusão.

**Separação de decimais**

O R utiliza o ponto (.) como separador decimal, enquanto a vírgula (,) é utilizada para separar argumentos e elementos.

## 2.6 Comentários

Tudo o que aparece após `#` em uma linha é interpretado como comentário e não é executado.

```
# Conversao de um preco de milhares para unidades monetarias
preco <- 25.4 * 1000
```

Comentários devem registrar a intenção de uma etapa, e não apenas repetir literalmente o comando.

## 2.7 Consultando a ajuda

O R possui documentação integrada. Para consultar uma função:

```
?mean
help(mean)
```

Para procurar documentação relacionada a um termo:

```
help.search("histogram")
```

**Erro comum**

R diferencia letras maiúsculas de minúsculas. Assim, `mean`, `Mean` e `MEAN` são nomes diferentes. A função correta para calcular a média é `mean()`.

**Exercício prático – Seção 2**

No seu *script*:

1. calcule $18 + 27$;
2. calcule $7^2$;
3. calcule $\sqrt{144}$ com uma função do R;
4. arredonde 8,376491 para duas casas decimais;
5. crie o objeto `custo <- 125.50`;
6. crie o objeto `quantidade <- 40`;
7. calcule `custo * quantidade` e armazene o resultado em `valor_total`;
8. consulte a ajuda da função `sum()`.

# 3 Banco de dados da oficina: Cars93

**Objetivos da seção**

Ao final desta seção, o participante deverá ser capaz de:

- carregar um banco disponibilizado por um pacote do R;
- compreender a estrutura de um *data frame*;
- reconhecer os principais tipos de variáveis presentes no banco;
- interpretar os nomes e as unidades das variáveis utilizadas na oficina.

## 3.1 Contexto do banco

O banco `Cars93`, do pacote `MASS`, reúne informações sobre 93 modelos de automóveis comercializados nos Estados Unidos em 1993. Os veículos foram selecionados entre modelos listados em fontes de avaliação e compra de automóveis daquele período. O conjunto original possui 27 variáveis, incluindo características econômicas, de desempenho, consumo, dimensões, capacidade e origem do fabricante (Lock, 1993; Venables e Ripley, 2002).

O banco permite formular perguntas como:

- veículos mais potentes tendem a apresentar maior preço de venda?
- veículos mais pesados apresentam menor eficiência de combustível?
- o preço varia entre categorias de automóveis?
- determinadas categorias estão mais associadas a fabricantes dos Estados Unidos ou de outros países?

**Preço não é custo de produção**

A variável `Price` representa preço de venda de referência, em milhares de dólares, e não custo industrial de fabricação.

## 3.2 Carregando o banco

O pacote `MASS` normalmente acompanha instalações padrão do R como pacote recomendado. Carregue diretamente o banco com:

```
data("Cars93", package = "MASS")
```

Se o R informar que o pacote `MASS` não está instalado, execute apenas uma vez:

```
install.packages("MASS")
```

e repita o comando anterior.

Para simplificar, trabalharemos com um subconjunto das variáveis:

```
dados <- Cars93[, c("Manufacturer", "Model", "Type", "Price",
"MPG.city", "MPG.highway", "DriveTrain",
"EngineSize", "Horsepower", "Weight", "Origin")]
```

## 3.3 Tradução das variáveis

Os nomes originais serão mantidos no código porque correspondem à documentação do banco. A tabela abaixo fornece a tradução e a interpretação de cada variável utilizada.

| Variável no R | Tradução | Interpretação |
|---|---|---|
| `Manufacturer` | Fabricante | empresa fabricante do automóvel |
| `Model` | Modelo | modelo comercial do automóvel |
| `Type` | Categoria/tipo | Small, Sporty, Compact, Midsize, Large ou Van |
| `Price` | Preço médio | média entre preço mínimo e máximo, em milhares de dólares |
| `MPG.city` | Eficiência de combustível na cidade | milhas percorridas por galão de combustível em ciclo urbano |
| `MPG.highway` | Eficiência de combustível na estrada | milhas percorridas por galão em rodovia |
| `DriveTrain` | Tipo de tração | tração dianteira, traseira ou nas quatro rodas |
| `EngineSize` | Cilindrada | tamanho do motor, em litros |
| `Horsepower` | Potência | potência máxima do motor, em horsepower (hp) |
| `Weight` | Peso | peso do veículo, em libras |
| `Origin` | Origem | fabricante dos Estados Unidos ou de outro país |

**Unidades do banco**

O conjunto é histórico e utiliza unidades usuais nos Estados Unidos. Nesta oficina, manteremos as unidades originais para concentrar a atenção na análise de dados. Em um projeto de Engenharia, conversões para o Sistema Internacional devem ser documentadas explicitamente.

## 3.4 O que é um data frame?

Em análise de dados, é comum organizar informações em uma estrutura retangular na qual:

- cada **linha** representa uma observação ou unidade de análise;
- cada **coluna** representa uma variável;
- cada célula contém o valor de uma variável para determinada observação.

No banco `dados`, cada linha corresponde a um modelo de automóvel e cada coluna corresponde a uma característica do modelo.

```
class(dados)
dim(dados)
```

**Exercício prático – Seção 3**

1. carregue `Cars93` e crie o objeto `dados` com as variáveis selecionadas;
2. execute `class(dados)`;
3. execute `dim(dados)` e interprete o resultado;
4. consulte `?Cars93`;
5. identifique, na documentação, a unidade de `Price`, `EngineSize` e `Weight`;
6. escolha duas variáveis para analisar desempenho e duas para analisar aspectos financeiros.

# 4 Inspeção, seleção e qualidade dos dados

**Objetivos da seção**

Ao final desta seção, o participante deverá ser capaz de:

- inspecionar dimensões, nomes, classes e conteúdo de um banco;
- acessar colunas e selecionar subconjuntos;
- filtrar observações com condições lógicas;
- identificar valores ausentes;
- exportar e importar um arquivo CSV.

## 4.1 Inspeção inicial

Nunca inicie uma análise aplicando funções estatísticas sem antes verificar a estrutura dos dados. Um conjunto mínimo de comandos é:

```
head(dados)
tail(dados)
dim(dados)
nrow(dados)
ncol(dados)
names(dados)
str(dados)
summary(dados)
```

Interpretação:

- `head()` mostra as primeiras linhas;
- `tail()` mostra as últimas linhas;
- `dim()` retorna número de linhas e colunas;
- `names()` retorna os nomes das variáveis;
- `str()` apresenta uma descrição compacta da estrutura e das classes;
- `summary()` produz um resumo dependente do tipo de cada variável.

**Por que usar `str()`?**

A aparência de uma coluna não garante seu tipo computacional. Uma variável codificada por números pode representar categorias, enquanto uma coluna aparentemente numérica pode ter sido importada como texto. Inspecionar a estrutura é uma etapa de controle de qualidade.

No R, as variáveis são armazenadas em objetos com diferentes tipos ou classes, que determinam como seus valores são representados e quais operações podem ser realizadas. As classes mais comuns são:

- **numeric**: valores numéricos, inteiros ou decimais, utilizados em cálculos;
- **integer**: números inteiros armazenados explicitamente como inteiros;
- **character**: textos ou cadeias de caracteres;
- **logical**: valores lógicos, `TRUE` ou `FALSE`;
- **factor**: variáveis categóricas representadas por um conjunto definido de níveis.

## 4.2 Acessando colunas

O operador `$` permite acessar uma coluna pelo nome:

```
dados$Price
dados$Horsepower
dados$Type
```

Para um *data frame*, a lógica de indexação é:

```
dados[linhas, colunas]
```

Exemplos:

```
dados[1, ]
dados[, 4]
dados[1:5, 1:4]
dados[1:10, c("Model", "Type", "Price", "Horsepower")]
```

## 4.3 Filtrando linhas

Suponha que seja necessário selecionar apenas veículos compactos:

```
compactos <- dados[dados$Type == "Compact", ]
head(compactos)
dim(compactos)
```

Para selecionar veículos com preço inferior a 20 mil dólares:

```
preco_ate20 <- dados[dados$Price < 20, ]
head(preco_ate20)
```

Para combinar condições:

```
filtro <- dados[dados$Price < 20 & dados$Horsepower >= 120, ]
filtro[, c("Model", "Price", "Horsepower")]
```

**Erro comum**

Filtrar dados altera o conjunto de observações utilizado na análise. Depois de criar um subconjunto, confira `dim()`, `head()` e, quando pertinente, tabelas ou resumos. Um filtro logicamente incorreto pode produzir resultados numericamente válidos para o subconjunto errado.

## 4.4 Valores ausentes

O R utiliza `NA` para representar valores ausentes. Para verificar a quantidade de valores ausentes em cada variável:

```
colSums(is.na(dados))
```

Também podemos verificar uma variável específica:

```r
sum(is.na(dados$Price))
sum(is.na(dados$Weight))
```

Quando houver valores ausentes, muitas funções retornam `NA` se nenhuma instrução adicional for fornecida. Quando for estatisticamente justificável calcular uma medida apenas com os valores observados, várias funções aceitam `na.rm = TRUE`.

```r
mean(dados$Price, na.rm = TRUE)
```

**Tratamento estatístico de dados ausentes**

O argumento `na.rm = TRUE` apenas remove valores ausentes daquele cálculo. Ele não resolve, por si só, o problema estatístico de dados faltantes. Em aplicações reais, o mecanismo de ausência, a quantidade de perdas e o possível viés devem ser investigados.

## 4.5 Exportando e importando um CSV

Para verificar o diretório de trabalho e seus arquivos:

```r
getwd()
list.files()
```

Para gravar o subconjunto utilizado na oficina naquele diretório:

```r
write.csv(dados, "cars93_oficina.csv", row.names = FALSE)
```

Para importar novamente:

```r
dados_importados <- read.csv("cars93_oficina.csv")
head(dados_importados)
str(dados_importados)
```

**Exercício prático – Seção 4**

Utilize `dados` e execute as tarefas.

1. verifique as dimensões e os nomes das variáveis;
2. use `str()` e identifique quais variáveis são quantitativas e quais são qualitativas;
3. selecione as oito primeiras linhas e as colunas `Model`, `Type`, `Price` e `Horsepower`;
4. crie um objeto contendo apenas veículos `Sporty`;
5. crie um objeto contendo veículos com `MPG.city >= 25`;
6. conte os valores ausentes em todas as variáveis com `colSums(is.na(dados))`;
7. exporte `dados` para `cars93_oficina.csv` e importe-o novamente.

# 5 Análise exploratória unidimensional

**Objetivos da seção**

Ao final desta seção, o participante deverá ser capaz de:

- calcular e interpretar medidas de posição e dispersão;
- construir tabelas de frequências absolutas e relativas;
- escolher representações gráficas adequadas ao tipo de variável;
- construir e interpretar gráficos de barras, histogramas e *boxplots*.

## 5.1 A análise descritiva como etapa de exploração

A análise exploratória organiza e sintetiza características observadas nos dados. Não trate-a como mera produção automática de números: a escolha das medidas e representações depende do tipo da variável, da distribuição dos dados e da pergunta de interesse (Tukey, 1977; Montgomery e Runger, 2018).

Para uma análise unidimensional, uma orientação inicial é:

| Tipo de variável | Recursos iniciais |
|---|---|
| qualitativa | tabela de frequências e gráfico de barras |
| quantitativa | medidas descritivas, histograma e *boxplot* |

**Princípio de clareza**

Um gráfico deve responder a uma pergunta e apresentar informações suficientes para ser interpretado corretamente. Títulos, eixos e unidades devem ser identificados sempre que forem necessários para compreender o fenômeno representado.

## 5.2 Variáveis qualitativas

### 5.2.1 Tabelas de frequência e gráfico de barras

Para descrever a distribuição da variável qualitativa `Type`, inicialmente construímos uma tabela de frequências:

```
tab_tipo <- table(dados$Type)
tab_tipo
prop.table(tab_tipo)
round(100 * prop.table(tab_tipo), 1)
```

A função `table()` produz as frequências absolutas. A função `prop.table()` transforma essas frequências em proporções; multiplicar o resultado por 100 fornece percentuais.

Uma representação gráfica adequada para uma variável qualitativa é o gráfico de barras:

```
barplot(tab_tipo,
main = "Numero de modelos por categoria",
xlab = "Categoria",
ylab = "Frequencia")
```

Cada barra representa uma categoria e sua altura indica a frequência correspondente. As barras permanecem separadas porque representam categorias distintas, e não intervalos de uma escala quantitativa.

## 5.3 Variáveis quantitativas

### 5.3.1 Medidas de posição

Considere `Price`, o preço médio do modelo em milhares de dólares. Para uma variável quantitativa $x_1, \ldots, x_n$, a média amostral é

$$\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i.$$

Em R:

```
mean(dados$Price)
median(dados$Price)
```

A média utiliza todos os valores e é sensível a observações extremas. A mediana corresponde ao valor central da distribuição ordenada e tende a ser mais robusta a valores extremos.

### 5.3.2 Mínimo, máximo, amplitude e quantis

```
min(dados$Price)
max(dados$Price)
range(dados$Price)
diff(range(dados$Price))
quantile(dados$Price)
IQR(dados$Price)
```

A função `range()` retorna o mínimo e o máximo. Aplicar `diff()` ao resultado produz a amplitude total. Por padrão, `quantile()` retorna mínimo, primeiro quartil, mediana, terceiro quartil e máximo. A função `IQR()` calcula o intervalo interquartil, dado pela diferença entre o terceiro e o primeiro quartis.

### 5.3.3 Variância e desvio-padrão

A variância amostral usual é

$$s^2 = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2,$$

e o desvio-padrão amostral é

$$s = \sqrt{s^2}.$$

Em R:

```
var(dados$Price)
sd(dados$Price)
```

**Interpretação**

O desvio-padrão está na mesma unidade da variável. Como `Price` está em milhares de dólares, seu desvio-padrão também está em milhares de dólares. A variância está na unidade ao quadrado e, por isso, costuma ser menos diretamente interpretável.

Como síntese das principais medidas, podemos utilizar:

```
summary(dados$Price)
```

A função `summary()` foi utilizada anteriormente na inspeção do banco. Para uma variável quantitativa, ela reúne mínimo, primeiro quartil, mediana, média, terceiro quartil e máximo.

### 5.3.4 Histograma

Para examinar a distribuição dos preços:

```
hist(dados$Price,
main = "Distribuicao dos precos dos veiculos",
xlab = "Preco medio (milhares de US$)",
ylab = "Frequencia")
```

O histograma divide a escala de uma variável quantitativa em intervalos e representa a frequência de observações em cada intervalo. Diferentemente do gráfico de barras, as classes representam intervalos consecutivos de uma escala numérica.

**Gráfico de barras versus histograma**

O gráfico de barras é utilizado para categorias; o histograma representa a distribuição de uma variável quantitativa por meio de intervalos. Embora visualmente semelhantes, os dois gráficos representam estruturas de dados diferentes.

A percepção da forma da distribuição pode mudar conforme o número e a largura das classes. Por padrão, `hist()` utiliza a regra de Sturges como uma sugestão para o número de classes. Essa regra é dada aproximadamente por

$$k = \lceil 1 + \log_2(n) \rceil ,$$

em que $n$ é o tamanho da amostra. O R pode ajustar os pontos de corte para valores convenientes, e o argumento `breaks` permite modificar o procedimento.

Por exemplo:

```
hist(dados$Price,
breaks = 20,
main = "Distribuicao dos precos dos veiculos",
xlab = "Preco medio (milhares de US$)",
ylab = "Frequencia")
```

Observe que 20 classes parece ser um número excessivo para representar adequadamente a distribuição dessa variável no histograma.

### 5.3.5 Boxplot

Outra representação importante para uma variável quantitativa é o *boxplot*:

```
boxplot(dados$Price,
main = "Boxplot dos precos dos veiculos",
ylab = "Preco medio (milhares de US$)")
```

O *boxplot* sintetiza aspectos da posição e da dispersão dos dados a partir dos quartis e permite identificar observações além dos limites convencionais dos "bigodes". Ele é particularmente útil para avaliar assimetria, dispersão e possíveis observações atípicas, mas não substitui a inspeção dos dados nem outras representações da distribuição.

**Exercício prático – Seção 5**

1. para `Horsepower`, calcule média, mediana, desvio-padrão, mínimo, máximo, quartis e intervalo interquartil;
2. construa a tabela de frequências absolutas e percentuais de `Type`;

3. construa um gráfico de barras para `Type`;
4. construa um histograma de `MPG.city`;
5. construa um *boxplot* de `Weight`;
6. escreva duas conclusões descritivas no *script* utilizando comentários.

# 6 Análise exploratória das relações entre variáveis

**Objetivos da seção**

Ao final desta seção, o participante deverá ser capaz de:

- analisar a relação entre duas variáveis quantitativas por meio de diagramas de dispersão e correlação;
- explorar conjuntamente várias variáveis quantitativas;
- comparar uma variável quantitativa entre categorias;
- construir e interpretar tabelas de contingência para duas variáveis qualitativas;
- interpretar associações sem confundi-las com relações causais.

A escolha da análise depende dos tipos das variáveis envolvidas:

| Variáveis | Recursos iniciais |
|---|---|
| duas quantitativas | diagrama de dispersão e correlação |
| quantitativa e qualitativa | medidas por grupos e *boxplots* comparativos |
| duas qualitativas | tabela de contingência e proporções |
| várias quantitativas | matriz de correlações, mapa de calor e matriz de dispersão |

## 6.1 Duas variáveis quantitativas

Uma questão de interesse é poder verificar, por exemplo, se veículos com maior potência tendem a apresentar preços maiores. O primeiro passo é examinar graficamente a relação entre as variáveis.

```
plot(dados$Horsepower,
dados$Price,
xlab = "Potencia maxima (hp)",
ylab = "Preco medio (milhares de US$)",
main = "Preco versus potencia")
```

O diagrama de dispersão representa cada observação por um ponto e permite examinar a direção, a forma e a intensidade aparente da associação, além de possíveis observações atípicas.

Uma medida numérica da associação linear é o coeficiente de correlação de Pearson:

```
cor(dados$Horsepower, dados$Price,
method = "pearson")
```

O coeficiente de correlação de Pearson varia entre $-1$ e 1. Valores positivos indicam associação linear positiva; valores negativos indicam associação linear negativa; e valores próximos de zero indicam pequena associação *linear*. Portanto, correlação próxima de zero não implica necessariamente ausência de qualquer relação entre as variáveis.

**Correlação e diagrama de dispersão**

A correlação fornece uma medida numérica da associação linear, enquanto o diagrama de dispersão permite examinar também a forma da relação, possíveis valores atípicos e padrões não lineares. As duas ferramentas devem ser interpretadas conjuntamente.

**Erro comum**

Correlação não estabelece causalidade. Uma associação entre potência e preço não demonstra que aumentar a potência, isoladamente, causa determinado aumento de preço. Categoria do veículo, fabricante, tecnologia, acabamento e outras características podem estar relacionadas simultaneamente às duas variáveis.

## 6.2 Várias variáveis quantitativas

Quando o banco contém várias variáveis quantitativas, podemos analisar simultaneamente suas associações lineares por meio de uma matriz de correlações.

Considere preço, eficiência de combustível, cilindrada, potência e peso:

```
vars <- dados[, c("Price",
"MPG.city",
"MPG.highway",
"EngineSize",
"Horsepower",
"Weight")]

mat_cor <- cor(vars, method = "pearson")
round(mat_cor, 2)
```

Cada elemento da matriz corresponde à correlação entre um par de variáveis. A matriz é simétrica e sua diagonal principal contém valores iguais a 1, pois cada variável apresenta correlação perfeita consigo mesma.

Valores próximos de 1 indicam associação linear positiva intensa; valores próximos de $-1$, associação linear negativa intensa; e valores próximos de zero indicam pequena associação linear.

**Interpretação**

A matriz de correlações permite identificar padrões entre várias variáveis, mas continua descrevendo associações lineares e não estabelece relações de causa e efeito.

A matriz pode ser representada graficamente por um *mapa de calor*. Uma escala divergente centrada em zero facilita a identificação do sinal e da magnitude das correlações: vermelho representa valores negativos; branco, valores próximos de zero; e azul, valores positivos.

```
cores <- colorRampPalette(
  c("red", "white", "blue")
)(100)

heatmap(mat_cor,
Rowv = NA,
Colv = NA,
scale = "none",
col = cores,
breaks = seq(-1, 1, length.out = 101),
margins = c(8, 8),
main = "Mapa de calor das correlacoes")
```

O argumento `breaks = seq(-1, 1, ...)` fixa a escala no intervalo possível do coeficiente de correlação. Assim, zero ocupa o centro da escala de cores e correlações positivas e negativas de mesma magnitude recebem intensidades comparáveis.

**Interpretação do mapa de calor**

Tons mais intensos de vermelho representam correlações negativas de maior magnitude, enquanto tons mais intensos de azul representam correlações positivas de maior magnitude. Células próximas do branco correspondem a correlações lineares próximas de zero.

Outra forma de explorar várias variáveis quantitativas é construir simultaneamente os diagramas de dispersão de todos os pares:

```
pairs(vars,
main = "Matriz de diagramas de dispersao")
```

Cada painel corresponde à relação entre duas variáveis. A função `pairs()` complementa a matriz de correlações porque permite avaliar visualmente a forma das relações e identificar padrões que um único coeficiente numérico pode não revelar.

## 6.3 Uma variável quantitativa e uma qualitativa

Quando uma variável quantitativa é analisada segundo categorias, podemos comparar medidas descritivas entre os grupos e utilizar *boxplots* comparativos.

Para comparar o preço entre as categorias de veículos:

```
aggregate(Price ~ Type,
data = dados,
FUN = mean)

boxplot(Price ~ Type,
data = dados,
main = "Preco por categoria de veiculo",
xlab = "Categoria",
ylab = "Preco medio (milhares de US$)")
```

A função `aggregate()`, tendo o argumento `FUN = mean`, calcula a média de `Price` separadamente para cada categoria de `Type`. O *boxplot* permite comparar simultaneamente posição, dispersão e possíveis observações atípicas entre os grupos.

A comparação deve considerar não apenas diferenças entre médias, mas também a variabilidade e a sobreposição das distribuições observadas.

## 6.4 Duas variáveis qualitativas

A relação entre duas variáveis qualitativas pode ser explorada por meio de uma tabela de contingência. Para estudar conjuntamente a categoria do veículo e a origem do fabricante:

```
tab2 <- table(dados$Type, dados$Origin)
tab2
```

Cada célula contém o número de observações correspondente à combinação entre uma categoria de `Type` e uma categoria de `Origin`.

As proporções globais são obtidas por:

```
prop.table(tab2)
```

Para calcular proporções dentro de cada linha:

```
prop.table(tab2, margin = 1)
```

Nesse caso, cada linha soma 1. Assim, podemos examinar como a origem dos fabricantes se distribui dentro de cada tipo de veículo.

Para proporções dentro de cada coluna:

```
prop.table(tab2, margin = 2)
```

Agora cada coluna soma 1, permitindo examinar como os tipos de veículos se distribuem dentro de cada origem.

**O denominador importa**

A interpretação de uma tabela de proporções depende do denominador utilizado. Proporções por linha e por coluna respondem a perguntas diferentes e não devem ser interpretadas como equivalentes.

**Exercício prático – Seção 6**

1. construa um diagrama de dispersão entre `Weight` e `MPG.highway` e calcule a correlação entre essas variáveis;
2. interprete a direção da associação observada, lembrando que valores maiores de `MPG.highway` representam maior eficiência de combustível;
3. construa a matriz de correlações das variáveis quantitativas utilizadas nesta seção e represente-a por meio de um mapa de calor;
4. compare o preço médio por `Origin` e construa *boxplots* de `Price` por `Origin`;
5. construa uma tabela de contingência entre `Type` e `DriveTrain`, calcule as proporções por linha (%) e apresente a resposta com 3 casas decimais;
6. escreva duas conclusões descritivas fundamentadas nos resultados e deixe explícito que elas se referem ao conjunto de veículos observado.

# 7 Análise integrada e reprodutibilidade

**Objetivos da seção**

Ao final desta seção, o participante deverá ser capaz de:

- organizar um fluxo simples de análise em um único *script*;
- separar preparação, inspeção, análise e visualização;
- registrar decisões por comentários;
- reconhecer princípios elementares de reprodutibilidade.

## 7.1 Do comando isolado ao fluxo de análise

Em uma análise real, comandos não devem formar uma coleção desordenada de tentativas. Um *script* deve permitir compreender a sequência lógica do trabalho. Uma estrutura simples é:

```
# ========================================================
# 1. Dados
# ========================================================

data("Cars93", package = "MASS")

dados <- Cars93[, c("Manufacturer", "Model", "Type", "Price",
"MPG.city", "MPG.highway", "DriveTrain",
"EngineSize", "Horsepower", "Weight", "Origin")]

# ========================================================
# 2. Inspecao
# ========================================================

head(dados)
dim(dados)
names(dados)
str(dados)
colSums(is.na(dados))

# ========================================================
# 3. Analise unidimensional
# ========================================================

mean(dados$Price, na.rm = TRUE)
median(dados$Price, na.rm = TRUE)
sd(dados$Price, na.rm = TRUE)
table(dados$Type)

# ========================================================
# 4. Analise bidimensional
# ========================================================

cor(dados$Horsepower, dados$Price,
method = "pearson")

aggregate(Price ~ Type,
data = dados,
FUN = mean)
```

```r
# ====================================================
# 5. Visualizacao
# ====================================================

hist(dados$Price,
main = "Distribuicao dos precos",
xlab = "Preco medio (milhares de US$)")

boxplot(Price ~ Type,
data = dados,
main = "Preco por categoria",
xlab = "Categoria",
ylab = "Preco medio (milhares de US$)")

plot(dados$Horsepower, dados$Price,
xlab = "Potencia maxima (hp)",
ylab = "Preco medio (milhares de US$)",
main = "Preco versus potencia")
```

Essa organização permite localizar rapidamente cada etapa e reduz a dependência do histórico interativo do console.

No RStudio, é possível organizar o *script* em seções utilizando comentários terminados por quatro ou mais hífens, o que facilita a navegação e a localização rápida dos blocos de código. Por exemplo:

```r
# Importacao dos dados ----

# Analise descritiva ----

# Graficos ----

# Analise bidimensional ----
```

Essas seções são reconhecidas pelo RStudio e podem ser acessadas rapidamente pelo menu de navegação do editor de *scripts*.

## 7.2 Reprodutibilidade

Uma análise computacional é reprodutível quando outra pessoa, dispondo dos mesmos dados, código e ambiente computacional adequado, consegue repetir os procedimentos e obter resultados equivalentes. *scripts* legíveis, dependências explícitas e dados identificados são componentes básicos desse princípio (Chambers, 2008; Wickham, Çetinkaya-Rundel e Grolemund, 2023).

Boas práticas iniciais:

- mantenha os comandos importantes no *script*;
- registre a origem dos dados;
- utilize nomes informativos para objetos;
- utilize comentários para registrar decisões analíticas;
- interprete cada resultado no contexto da variável;
- confira o código a partir de uma sessão limpa.

## 7.3 Erros fazem parte do processo

Quando um comando falha, leia a mensagem antes de fazer modificações aleatórias. Fontes frequentes de erro são:

1. nome de objeto ou variável digitado incorretamente;
2. parêntese, aspas ou vírgula ausente;
3. uso de maiúsculas e minúsculas diferente do nome original;
4. tentativa de utilizar um objeto que ainda não foi criado;
5. arquivo procurado em diretório diferente daquele em que foi salvo.

**Estratégia de depuração**

Ao encontrar um erro: (1) leia a mensagem; (2) identifique em qual comando ocorreu; (3) confira nomes, sinais e argumentos; (4) execute apenas a menor parte necessária do código; (5) consulte a ajuda da função quando necessário.

**Exercício prático – Seção 7 – desafio integrador**

Crie um novo *script* chamado `analise_cars93.R`. O *script* deve funcionar como uma análise completa e conter comentários separando as etapas.

1. carregue o banco `Cars93` e crie `dados`;
2. verifique dimensões, nomes, estrutura e valores ausentes;
3. produza uma tabela de frequências de `Type`;
4. calcule média, mediana e desvio-padrão de `Price`;
5. calcule o preço médio por `Type`;
6. construa um histograma de `Price`;
7. construa um boxplot de `Price` por `Type`;
8. construa um diagrama de dispersão entre `Horsepower` e `Price`;
9. calcule a correlação entre `Horsepower` e `Price`;
10. escreva três conclusões descritivas como comentários no final do *script*.

**Meta:** o *script* deve poder ser executado de cima para baixo sem depender de comandos que tenham sido digitados anteriormente apenas no console.

## Panorama geral dos comandos essenciais da oficina

| Comando | Finalidade |
|---|---|
| `x <- valor` | criar ou atualizar um objeto |
| `data("Cars93", package="MASS")` | carregar o banco Cars93 |
| `head(dados)` | mostrar as primeiras linhas |
| `dim(dados)` | obter número de linhas e colunas |
| `names(dados)` | listar nomes das variáveis |
| `str(dados)` | inspecionar a estrutura |
| `summary(dados)` | obter um resumo geral |
| `dados$variavel` | acessar uma coluna |
| `dados[linhas,colunas]` | selecionar partes do banco |
| `read.csv()` | importar arquivo CSV |
| `write.csv()` | exportar arquivo CSV |
| `is.na()` | identificar valores ausentes |
| `colSums(is.na(dados))` | contar ausências por coluna |
| `mean()` | calcular média |
| `median()` | calcular mediana |
| `sd()` | calcular desvio-padrão amostral |
| `var()` | calcular variância amostral |
| `quantile()` | calcular quantis |
| `IQR()` | calcular intervalo interquartil |
| `table()` | construir tabela de frequências ou contingência |
| `prop.table()` | converter frequências em proporções |
| `aggregate()` | calcular estatísticas por grupos |
| `cor()` | calcular correlação linear entre variáveis quantitativas |
| `colorRampPalette()` | criar uma paleta contínua de cores para representações gráficas |
| `heatmap()` | representar graficamente uma matriz por meio de um mapa de calor |
| `pairs()` | construir uma matriz de diagramas de dispersão entre várias variáveis quantitativas |
| `hist()` | construir histograma |
| `barplot()` | construir gráfico de barras |
| `boxplot()` | construir boxplot |
| `plot()` | construir, entre outros gráficos, diagrama de dispersão |
| `?funcao` | abrir documentação de uma função |
| `sessionInfo()` | registrar informações da sessão |

## O que estudar depois desta oficina?

Esta oficina cobre a camada inicial necessária para utilizar R em uma análise exploratória. Uma progressão recomendada é:

1. importação de planilhas e bancos de dados maiores;
2. tratamento sistemático de dados ausentes;
3. manipulação e transformação de dados;
4. visualização de dados mais avançada;
5. inferência estatística, testes de hipóteses e intervalos de confiança;
6. regressão e modelagem estatística;
7. planejamento e análise de experimentos;
8. documentos reproduzíveis com R Markdown;
9. controle de versão com Git em projetos de análise.

Para continuidade estruturada, Wickham, Çetinkaya-Rundel e Grolemund (2023) apresentam um fluxo moderno de ciência de dados, enquanto Chambers (2008) discute de forma mais profunda a linguagem e os princípios de programação em R. Para aplicações estatísticas em Engenharia, Montgomery e Runger (2018) fornecem uma referência abrangente.

# 8 Exercício final: análise de dados de qualidade do ar

**Objetivos da seção**

Ao final deste exercício, o participante deverá ser capaz de integrar os principais procedimentos apresentados na oficina em uma análise exploratória, utilizando um banco diferente daquele empregado nos exemplos anteriores.

## 8.1 Contexto do banco

Neste exercício será utilizado o banco `airquality`, disponível no pacote `datasets`, que acompanha a instalação padrão do R. O conjunto contém medições diárias de qualidade do ar e condições meteorológicas realizadas em Nova York entre maio e setembro de 1973.

As observações incluem concentração de ozônio, radiação solar, velocidade do vento e temperatura, além do mês e do dia em que cada medição foi realizada. Esse tipo de informação é relevante em monitoramento de processos ambientais, controle da qualidade do ar e estudo da relação entre condições atmosféricas e concentração de poluentes. O banco possui 153 observações e 6 variáveis.

Para carregar o banco:

```
data("airquality", package = "datasets")
```

Crie uma cópia para realizar a análise:

```
dados_ar <- airquality
```

## 8.2 Descrição das variáveis

Os nomes originais das variáveis serão mantidos no código. A tabela apresenta sua interpretação.

| Variável no R | Tradução | Interpretação |
|---|---|---|
| `Ozone` | Ozônio | concentração média de ozônio, em partes por bilhão (ppb) |
| `Solar.R` | Radiação solar | radiação solar medida em Langleys |
| `Wind` | Velocidade do vento | velocidade média do vento, em milhas por hora (mph) |
| `Temp` | Temperatura | temperatura máxima diária, em graus Fahrenheit (°F) |
| `Month` | Mês | mês da observação, codificado numericamente de 5 a 9, correspondendo a maio, junho, julho, agosto e setembro |
| `Day` | Dia | dia do mês em que a observação foi realizada |

**Tipo da variável e significado**

Embora `Month` e `Day` sejam armazenadas numericamente no R, elas representam informações de calendário. Em particular, `Month` pode ser utilizada como variável de agrupamento para comparar as medições entre os diferentes meses.

**Valores ausentes**

O banco contém valores ausentes. Portanto, antes de calcular medidas descritivas ou associações, verifique quais variáveis possuem `NA`. Quando apropriado, utilize argumentos como `na.rm = TRUE` ou `use = "complete.obs"`.

## 8.3 Problema

Uma equipe responsável pelo monitoramento ambiental deseja realizar uma análise exploratória das condições atmosféricas registradas durante o período observado. O objetivo é descrever as principais características dos dados e investigar possíveis associações entre concentração de ozônio e condições meteorológicas.

Utilizando os recursos apresentados durante a oficina, desenvolva uma análise exploratória completa do banco `airquality`.

Organize todos os comandos em um único *script*, utilizando seções para separar as etapas da análise.

```
# Dados ----

# Inspecao ----

# Valores ausentes ----

# Analise unidimensional ----

# Comparacao entre meses ----

# Relacoes entre variaveis ----

# Analise conjunta ----

# Conclusoes ----
```

**Atenção!**

Este é um exercício de análise exploratória. As associações observadas entre ozônio, temperatura, vento e radiação solar descrevem padrões existentes no conjunto analisado. Correlações, diferenças entre meses e padrões gráficos não constituem, isoladamente, evidência de relações causais.

# Gabarito comentado dos exercícios

Os códigos abaixo representam soluções possíveis. Em R, frequentemente existem várias formas corretas de obter o mesmo resultado. Os resultados numéricos apresentados referem-se ao banco `Cars93` do pacote `MASS`.

## Gabarito – Seção 1

```
R.version.string
```

O resultado de `R.version.string` depende da versão do R instalada no computador. O comando retorna uma cadeia de caracteres contendo a versão utilizada na sessão.

## Gabarito – Seção 2

```
18 + 27
7^2
sqrt(144)
round(8.376491, digits = 2)

custo <- 125.50
quantidade <- 40
valor_total <- custo * quantidade
valor_total

?sum
```

Os resultados numéricos são:

```
[1] 45
[1] 49
[1] 12
[1] 8.38
[1] 5020
```

O comando `?sum` abre a documentação da função `sum()` no painel de ajuda do RStudio.

## Gabarito – Seção 3

```
data("Cars93", package = "MASS")

dados <- Cars93[, c("Manufacturer", "Model", "Type", "Price",
"MPG.city", "MPG.highway", "DriveTrain",
"EngineSize", "Horsepower", "Weight", "Origin")]

class(dados)
dim(dados)

?Cars93
```

Os primeiros resultados são:

```
[1] "data.frame"

[1] 93 11
```

Portanto, o objeto `dados` é um *data frame* formado por 93 observações e 11 variáveis.

De acordo com a documentação do banco:

- `Price`: preço médio de referência, em milhares de dólares;
- `EngineSize`: cilindrada ou tamanho do motor, em litros;
- `Weight`: peso do veículo, em libras.

Uma resposta possível para o último item é:

- **desempenho**: `Horsepower` e `MPG.highway`;
- **análise econômica ou de produto**: `Price` e `Type`.

Outras escolhas são possíveis, desde que sejam coerentes com a finalidade atribuída à variável.

## Gabarito – Seção 4

### 1. Dimensões e nomes das variáveis

```
dim(dados)
names(dados)
```

```
[1] 93 11
```

O banco utilizado na oficina contém 93 linhas e 11 colunas.

### 2. Estrutura e classificação das variáveis

```
str(dados)
```

Considerando o significado das variáveis, podemos classificá-las em:

- **qualitativas**: `Manufacturer`, `Model`, `Type`, `DriveTrain` e `Origin`;
- **quantitativas**: `Price`, `MPG.city`, `MPG.highway`, `EngineSize`, `Horsepower` e `Weight`.

No objeto original, as variáveis qualitativas selecionadas são armazenadas como fatores, enquanto as quantitativas aparecem como objetos numéricos ou inteiros.

### 3. Seleção das oito primeiras observações

```
dados[1:8, c("Model", "Type", "Price", "Horsepower")]
```

### 4. Veículos da categoria Sporty

```
sporty <- dados[dados$Type == "Sporty", ]

head(sporty)
dim(sporty)
```

```
[1] 14 11
```

Há 14 modelos classificados como `Sporty` no conjunto observado.

### 5. Veículos com eficiência urbana de pelo menos 25 mpg

```
eficientes <- dados[dados$MPG.city >= 25, ]

head(eficientes)
dim(eficientes)
```

```
[1] 24 11
```

Assim, 24 dos 93 modelos apresentam `MPG.city >= 25`.

### 6. Valores ausentes

```
colSums(is.na(dados))
```

Para as 11 variáveis selecionadas na oficina, não existem valores ausentes:

```
Manufacturer      Model       Type      Price   MPG.city
0                 0           0         0       0
MPG.highway DriveTrain EngineSize Horsepower     Weight
0                 0           0         0       0
Origin
0
```

### 7. Exportação e importação

```
write.csv(dados,
"cars93_oficina.csv",
row.names = FALSE)

dados_importados <- read.csv("cars93_oficina.csv")

head(dados_importados)
dim(dados_importados)
str(dados_importados)
```

Espera-se novamente:

```
[1] 93 11
```

**Classes após a importação**

O formato CSV armazena os valores, mas não preserva necessariamente as classes dos objetos do R. Assim, variáveis originalmente armazenadas como fatores podem ser importadas como `character`. Por isso, após importar um arquivo, é recomendável utilizar `str()` para conferir a estrutura.

## Gabarito – Seção 5

### 1. Medidas descritivas de Horsepower

```
x <- dados$Horsepower

mean(x, na.rm = TRUE)
median(x, na.rm = TRUE)
sd(x, na.rm = TRUE)
```

```r
min(x, na.rm = TRUE)
max(x, na.rm = TRUE)
quantile(x, na.rm = TRUE)
IQR(x, na.rm = TRUE)
```

Os principais resultados são aproximadamente:

```
Media:
[1] 143.83

Mediana:
[1] 140

Desvio-padrao:
[1] 52.37

Minimo:
[1] 55

Maximo:
[1] 300

Quartis:
0%  25%  50%  75% 100%
55  103  140  170  300

Intervalo interquartil:
[1] 67
```

Portanto, 50% dos modelos observados apresentam potência entre 103 e 170 hp. A mediana é 140 hp e a potência varia de 55 a 300 hp.

### 2. Frequências de Type

```r
tab_tipo <- table(dados$Type)
tab_tipo

round(100 * prop.table(tab_tipo), 1)
```

```
Compact   Large Midsize   Small  Sporty     Van
16       11       22       21       14        9

Compact   Large Midsize   Small  Sporty     Van
17.2    11.8    23.7    22.6    15.1     9.7
```

As categorias mais frequentes são `Midsize`, com 22 modelos, e `Small`, com 21. A categoria menos frequente é `Van`, com 9 modelos.

### 3. Gráfico de barras de Type

```r
barplot(tab_tipo,
main = "Numero de modelos por categoria",
xlab = "Categoria",
ylab = "Frequencia")
```

O gráfico deve reproduzir visualmente as frequências apresentadas na tabela anterior.

### 4. Histograma de MPG.city

```
hist(dados$MPG.city,
main = "Distribuicao da eficiencia urbana",
xlab = "Eficiencia urbana (milhas por galao)",
ylab = "Frequencia")
```

O histograma mostra maior concentração dos modelos em valores relativamente baixos ou intermediários de eficiência urbana e uma extensão da distribuição para valores elevados de `MPG.city`.

### 5. Boxplot de Weight

```
boxplot(dados$Weight,
main = "Boxplot do peso dos veiculos",
ylab = "Peso (libras)")
```

O gráfico permite examinar a posição central, a dispersão e a presença de possíveis observações extremas no peso dos veículos.

### 6. Exemplos de conclusões

No *script*, as conclusões poderiam ser registradas como:

```
# A potencia mediana dos 93 modelos observados e 140 hp,
# e 50% das potencias estao entre 103 e 170 hp.

# Midsize e Small sao as categorias mais frequentes no conjunto,
# enquanto Van e a categoria menos frequente.
```

Essas conclusões são descritivas e se referem exclusivamente aos veículos presentes no banco.

## Gabarito – Seção 6

### 1. Peso e eficiência de combustível em rodovia

```
plot(dados$Weight,
dados$MPG.highway,
xlab = "Peso (libras)",
ylab = "Eficiencia em rodovia (milhas por galao)",
main = "Eficiencia em rodovia versus peso")

cor(dados$Weight,
dados$MPG.highway,
method = "pearson")
```

O coeficiente de correlação é aproximadamente:

```
[1] -0.8106581
```

Há, portanto, uma associação linear negativa intensa entre peso e eficiência em rodovia no conjunto observado.

Como valores maiores de `MPG.highway` significam maior número de milhas percorridas por galão, os dados indicam que veículos mais pesados tendem a apresentar menor eficiência de combustível em rodovia.

Essa conclusão é associativa e descritiva; não estabelece uma relação causal.

### 2. Matriz de correlações

```
vars <- dados[, c("Price",
"MPG.city",
"MPG.highway",
"EngineSize",
"Horsepower",
"Weight")]

mat_cor <- cor(vars, method = "pearson")
round(mat_cor, 2)
```

A saída é uma matriz simétrica $6 \times 6$, com valores iguais a 1 na diagonal principal.

Entre os padrões que devem ser observados estão associações negativas entre peso e eficiência de combustível e associações positivas entre características como cilindrada, potência e peso.

### 3. Mapa de calor

```
cores <- colorRampPalette(
c("blue", "white", "red")
)(100)

heatmap(mat_cor,
Rowv = NA,
Colv = NA,
scale = "none",
col = cores,
breaks = seq(-1, 1, length.out = 101),
margins = c(8, 8),
main = "Mapa de calor das correlacoes")
```

No mapa de calor:

- azul representa correlações negativas;
- branco representa correlações próximas de zero;
- vermelho representa correlações positivas;
- maior intensidade da cor representa maior magnitude da correlação.

### 4. Preço por origem

```
preco_origem <- aggregate(Price ~ Origin,
data = dados,
FUN = mean)

preco_origem
```

Os resultados são aproximadamente:

```
  Origin    Price
1    USA 18.57292
2 non-USA 20.50889
```

Assim, no conjunto observado, o preço médio dos modelos de fabricantes não estadunidenses é aproximadamente 20,51 mil dólares, enquanto o preço médio dos modelos de fabricantes dos Estados Unidos é aproximadamente 18,57 mil dólares.

O boxplot é obtido por:

```
boxplot(Price ~ Origin,
data = dados,
main = "Preco por origem",
xlab = "Origem",
ylab = "Preco medio (milhares de US$)")
```

Além da diferença entre os centros das distribuições, o gráfico permite observar diferenças de dispersão e modelos de preço relativamente elevado, particularmente entre os veículos de origem não estadunidense.

### 5. Tipo de veículo e tipo de tração

```
tab_tracao <- table(dados$Type,
dados$DriveTrain)

tab_tracao
```

```
        4WD Front Rear
Compact     1    13    2
Large       0     7    4
Midsize     0    17    5
Small       2    19    0
Sporty      2     7    5
Van         5     4    0
```

As proporções por linha são:

```
round(100*prop.table(tab_tracao, margin = 1), 3)
```

```
        4WD Front  Rear
Compact  0.062 0.812 0.125
Large    0.000 0.636 0.364
Midsize  0.000 0.773 0.227
Small    0.095 0.905 0.000
Sporty   0.143 0.500 0.357
Van      0.556 0.444 0.000
```

Por exemplo, entre os modelos `Small`, aproximadamente 90,5% apresentam tração dianteira. Entre as vans, aproximadamente 55,6% apresentam tração nas quatro rodas.

### 6. Exemplos de conclusões descritivas

```
# No conjunto observado, peso e eficiencia em rodovia apresentam
# forte associacao linear negativa (r aproximadamente -0.81).

# Os modelos de fabricantes non-USA apresentam preco medio
# aproximadamente 20.51 mil dolares, contra 18.57 mil dolares
# para os modelos de fabricantes dos Estados Unidos.

# A tracao dianteira predomina em varias categorias, incluindo
# Small, Compact e Midsize; entre as Vans, a tracao 4WD e mais frequente.
```

Essas afirmações descrevem os 93 modelos presentes no banco e não devem ser generalizadas automaticamente para outros períodos, mercados ou populações de veículos.

## Gabarito – Seção 7

Uma solução completa para o desafio integrador é:

```
# Dados ----

data("Cars93", package = "MASS")

dados <- Cars93[, c("Manufacturer", "Model", "Type", "Price",
"MPG.city", "MPG.highway", "DriveTrain",
"EngineSize", "Horsepower", "Weight", "Origin")]

# Inspecao dos dados ----

dim(dados)
names(dados)
str(dados)
colSums(is.na(dados))

# Frequencias ----

tab_tipo <- table(dados$Type)
tab_tipo

round(100 * prop.table(tab_tipo), 1)

# Analise descritiva do preco ----

mean(dados$Price, na.rm = TRUE)
median(dados$Price, na.rm = TRUE)
sd(dados$Price, na.rm = TRUE)

# Preco medio por categoria ----

preco_tipo <- aggregate(Price ~ Type,
data = dados,
FUN = mean)

preco_tipo

# Histograma do preco ----

hist(dados$Price,
main = "Distribuicao dos precos",
xlab = "Preco medio (milhares de US$)",
ylab = "Frequencia")

# Boxplot do preco por categoria ----

boxplot(Price ~ Type,
data = dados,
main = "Preco por categoria",
xlab = "Categoria",
ylab = "Preco medio (milhares de US$)")

# Potencia versus preco ----

plot(dados$Horsepower,
dados$Price,
```

```
xlab = "Potencia maxima (hp)",
ylab = "Preco medio (milhares de US$)",
main = "Preco versus potencia")

cor(dados$Horsepower,
dados$Price,
method = "pearson")

# Conclusoes ----

# 1. O preco medio dos modelos observados e aproximadamente
# 19.51 mil dolares, enquanto a mediana e 17.70 mil dolares.
# A media superior a mediana e os valores elevados observados
# sugerem assimetria da distribuicao para a direita.

# 2. A categoria Midsize apresenta o maior preco medio entre
# as categorias observadas, enquanto Small apresenta o menor.

# 3. Potencia e preco apresentam forte associacao linear
# positiva no conjunto observado (r aproximadamente 0.79).
# Essa associacao nao deve ser interpretada como causalidade.
```

Os resultados centrais da análise são:

```
Dimensoes:
[1] 93 11

Frequencias de Type:
Compact   Large Midsize   Small  Sporty     Van
16      11      22      21      14       9

Preco:
Media        = 19.51
Mediana      = 17.70
Desvio-padrao = 9.66
```

Os preços médios por categoria são aproximadamente:

```
Type    Price
1 Compact 18.21250
2   Large 24.30000
3 Midsize 27.21818
4   Small 10.16667
5  Sporty 19.39286
6     Van 19.10000
```

A correlação entre potência e preço é:

```
[1] 0.7882176
```

Portanto, no conjunto observado, veículos com maior potência tendem a apresentar preços maiores. A magnitude do coeficiente indica uma associação linear positiva relativamente intensa, mas não permite concluir que maior potência seja, isoladamente, a causa de preços mais elevados.

**Reprodutibilidade do desafio**

O *script* acima pode ser executado integralmente, de cima para baixo, em uma nova sessão do R, sem depender de objetos previamente criados no console. Essa propriedade constitui uma condição básica para uma análise computacional reprodutível.

# Referências

CHAMBERS, J. M.; CLEVELAND, W. S.; KLEINER, B.; TUKEY, P. A. *Graphical Methods for Data Analysis*. Belmont: Wadsworth & Brooks/Cole, 1983.

CHAMBERS, J. M. *Software for Data Analysis: Programming with R*. New York: Springer, 2008. DOI: https://doi.org/10.1007/978-0-387-75936-4.

LOCK, R. H. 1993 new car data. *Journal of Statistics Education*, v. 1, n. 1, 1993. DOI: https://doi.org/10.1080/10691898.1993.11910459.

MONTGOMERY, D. C.; RUNGER, G. C. *Applied Statistics and Probability for Engineers*. 7. ed. Hoboken: Wiley, 2018.

POSIT SOFTWARE, PBC. *RStudio IDE User Guide*. 2026. Disponível em: https://docs.posit.co/ide/user/. Download: https://docs.posit.co/ide/user/download.html. Acesso em: 2 nov. 2026.

R CORE TEAM. *R: A Language and Environment for Statistical Computing*. Vienna: R Foundation for Statistical Computing, 2026. Disponível em: https://www.R-project.org/. Download: https://cran.r-project.org/. Acesso em: 2 nov. 2026.

TUKEY, J. W. *Exploratory Data Analysis*. Reading: Addison-Wesley, 1977.

VENABLES, W. N.; RIPLEY, B. D. *Modern Applied Statistics with S*. 4. ed. New York: Springer, 2002.

WICKHAM, H.; ÇETINKAYA-RUNDEL, M.; GROLEMUND, G. *R for Data Science: Import, Tidy, Transform, Visualize, and Model Data*. 2. ed. Sebastopol: O'Reilly Media, 2023. Disponível em: https://r4ds.hadley.nz/.